

## Exercice 1: Régression linéaire

```
In [1]: import numpy as np
import matplotlib.pyplot as plt
```


### 1 & 2- Génération d'un ensemble de données aléatoires

```
In [2]: np.random.seed(0)
X = 2 + np.random.rand(100, 1)
y1 = 4 + 3 * X
y = 4 + 3 * X + np.random.randn(100, 1)
```

### 3- Représentation graphique de la dispersion de y en fonction

```
In [3]: plt.rcParams.update({'font.size': 12})
fig = plt.figure(figsize=(12, 4))
plt.subplot(121)
plt.scatter(X,y1)
plt.xlabel("x")
plt.ylabel("y")
plt.ylim(2,12)
plt.title("y = 4 + 3x")
plt.subplot(122)
plt.rcParams.update({'font.size': 12})
plt.scatter(X,y)
plt.xlabel("x")
plt.ylabel("y")
plt.title("y = 4 + 3x + bruit")
plt.ylim(2,12)
```

Out[3]: (2.0, 12.0)



### 4- Implémentation analytique

```
In [4]: # On doit ajouter x0 = 1 à chaque observation
# Ensuite on implémente l'équation normale

X_b = np.c_[np.ones((100, 1)), X]
theta_hat = np.linalg.inv(X_b.T.dot(X_b)).dot(X_b.T).dot(y)
theta_hat
```

Out[4]: array([[4.22215108],
[2.96846751]])

On obtient les valeurs de  $\theta_0 = 4.10$  et  $\theta_1 = 2.77$ . L'équation de régression linéaire est alors  $y_{pred} = \theta_0 + \theta_1 x$  c-à-d  $y = 4.22 + 2.96 x$

### 6 & 7 - Impact du pas d'apprentissage

```
In [5]: # Fonction utilisé pour la représentation de la droite de régression
def DrawTheta(X,Y,eta,Theta,X_b,m,Color,LineWidth):
    # Plot init 'Theta'
    gradients = 2/m * X_b.T.dot(X_b.dot(Theta) - Y)
    Theta = Theta - eta * gradients
    y_pred = Theta[0] + Theta[1] * X
    plt.plot(X,y_pred, Color, linewidth=LineWidth)
    return Theta
```

```
In [6]: # On doit ajouter x0 = 1 à chaque observation
# Fixer la valeur de l'hyperparamètre qui correspond au nombre d'itération.
# Le pas d'apprentissage étant un hyperparamètre mais qui sera variable
# thetaInit est une initialisation aléatoire des valeurs de theta
# La représentation graphique est réalisée pour les 10 première itérations
```

```
m=100
n_iteations = 1000
X_b = np.c_[np.ones((100, 1)), X]
List_eta=[0.02, 0.1, 0.5]
thetaInit = np.random.randn(2,1)

fig = plt.figure(figsize=(15, 5))

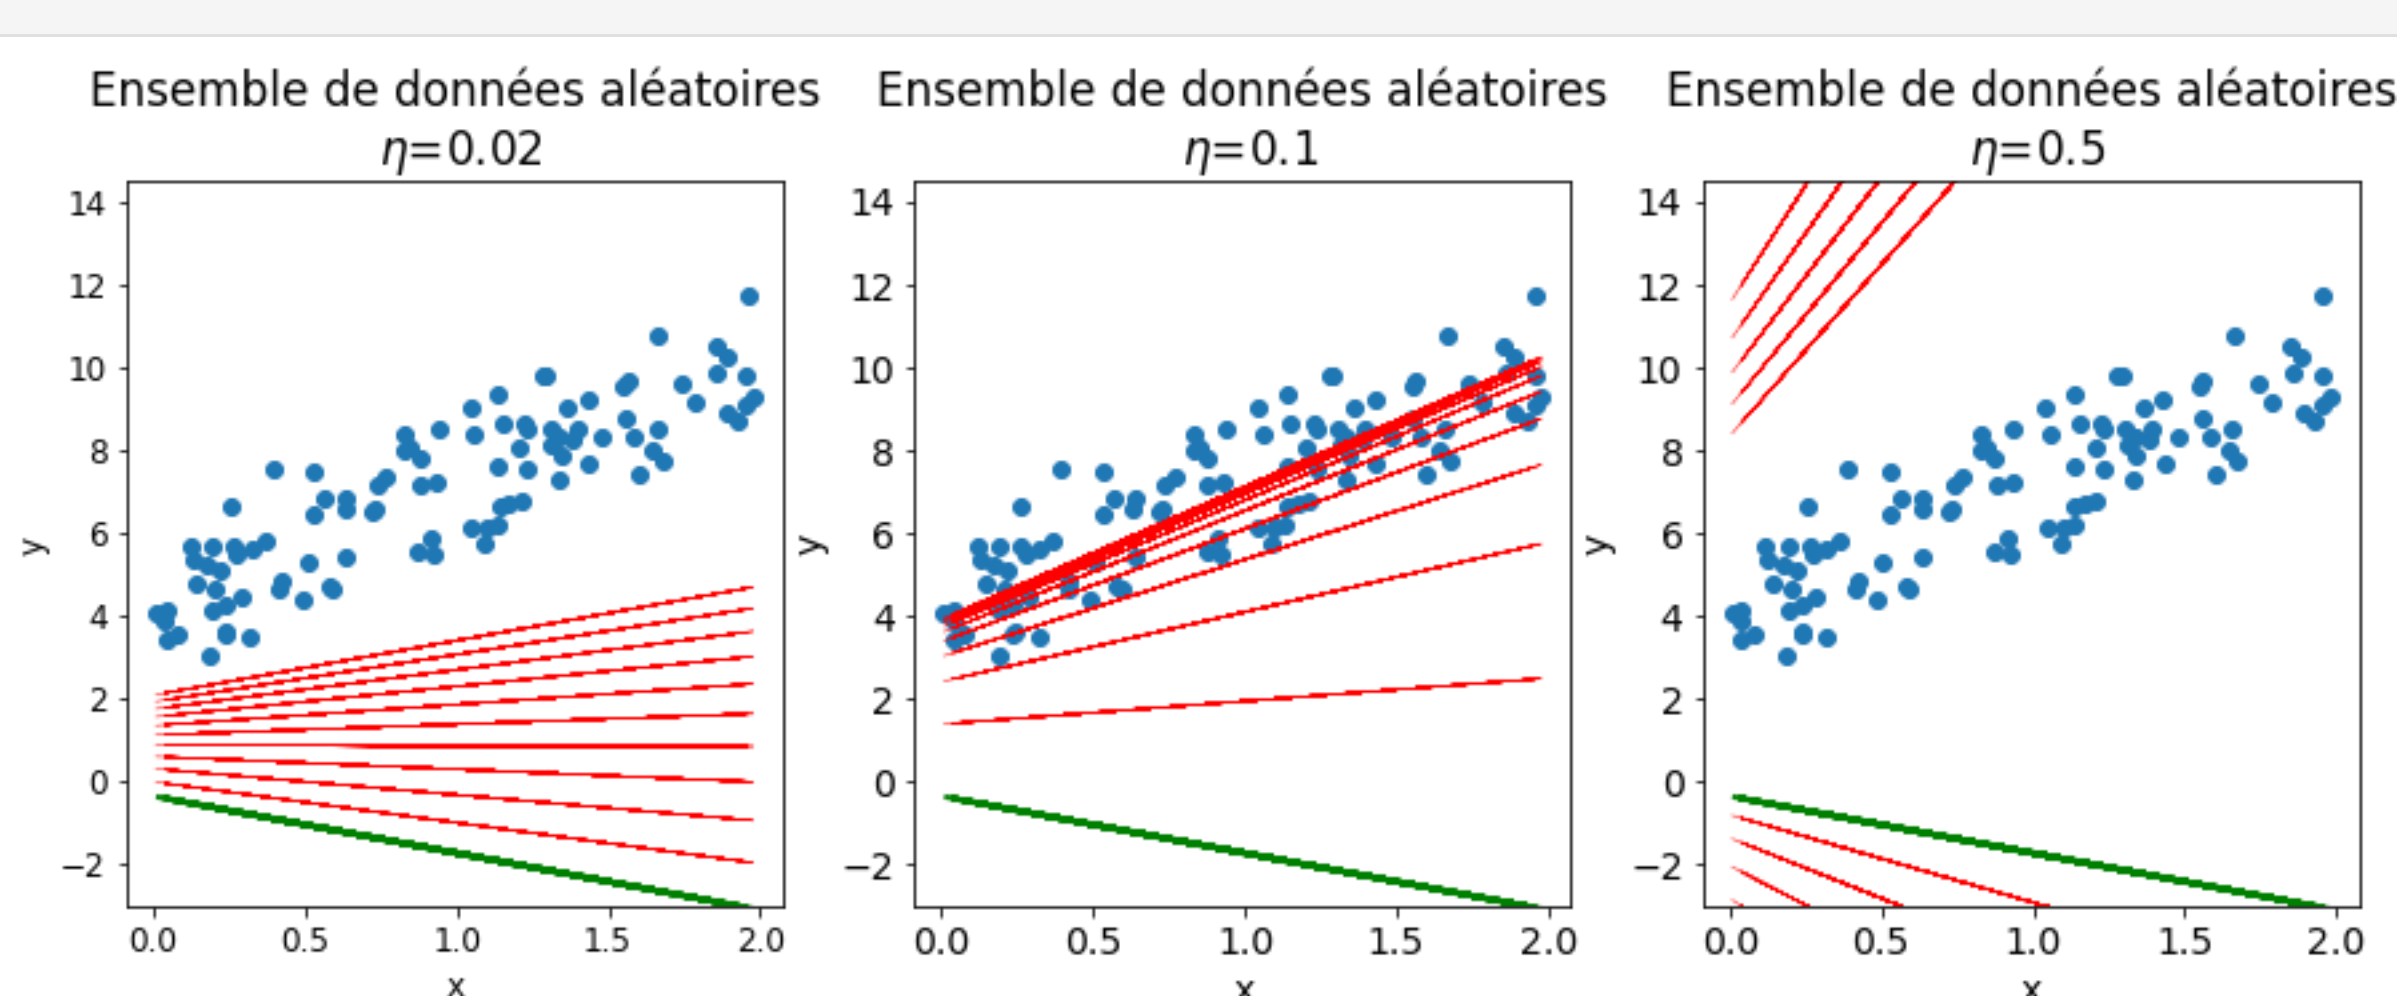
for i, eta in zip(np.arange(len(List_eta))+1, List_eta):
    theta=thetaInit

    plt.subplot(1, 3, i)
    plt.rcParams.update({'font.size': 14})
    plt.scatter(X,y)
    plt.xlabel("x")
    plt.ylabel("y")
    plt.title("Ensemble de données aléatoires\n " + r'$\eta$='+str(eta))

    # Plot init 'Theta'
    y_pred = thetaInit[0] + thetaInit[1] * X
    plt.plot(X,y_pred, 'g--', linewidth=2)

    for iteration in range(n_iteations):
        if (iteration < 10):
            theta=DrawTheta(X,y,eta,theta,X_b,m,'r',0.5)

    plt.ylim(-3, 14.5)
    plt.plot()
```



### 8-Modèle de régression avec la classe SGDRegressor

```
In [7]: # Modèle linéaire ajusté en se basant sur une descente
# de gradient stochastique
from sklearn.linear_model import SGDRegressor

sgd_reg = SGDRegressor(max_iter=1000, tol=-3, penalty=None, eta=0.1)
sgd_reg.fit(X, y.ravel())
sgd_reg.intercept_, sgd_reg.coef_
```

Out[7]: (array([4.17429195]), array([2.90225601]))

On obtient les valeurs de  $\theta_0 = 4.10$  et  $\theta_1 = 2.77$ . L'équation de régression linéaire est alors  $y_{pred} = \theta_0 + \theta_1 x$  c-à-d  $y = 4.17 + 2.90 x$

## Exercice2 : Regression polynomiale

```
In [8]: import numpy as np
import numpy.random as rnd
import numpy as np
import matplotlib.pyplot as plt
```

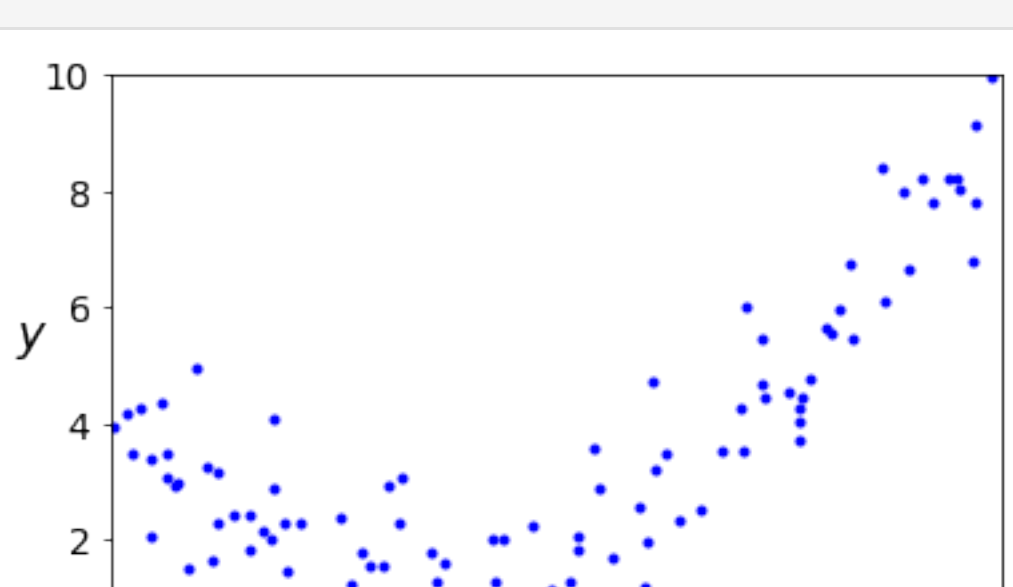
```
In [9]: np.random.seed(42)
```

### 1 & 2 - Génération des données

```
In [10]: m = 100
X = 6 * np.random.rand(m, 1) - 3
y = 0.5 * X**2 + X + 2 + np.random.randn(m, 1)
```

### 3- Représentation de y en fonction de x

```
In [11]: plt.plot(X, y, "b.")
plt.xlabel("$x_1$", fontsize=18)
plt.ylabel("$y$", rotation=0, fontsize=18)
plt.axis([-3, 3, 0, 10])
plt.show()
```



### 4- Génération d'un modèle de caractéristiques polynomiaux

```
In [12]: # Génère une nouvelle matrice de caractéristiques composée
# de toutes les combinaisons polynomiales des caractéristiques
# avec un degré inférieur ou égal au degré spécifié.
# Dans notre cas degree=2

from sklearn.preprocessing import PolynomialFeatures
poly_features = PolynomialFeatures(degree=2, include_bias=False)
X_poly = poly_features.fit_transform(X)
```

```
In [13]: # Vérification avec une valeur scalaire de X
X[0]
```

Out[13]: array([-0.75275929])

```
In [14]: # On obtient un vecteur à deux valeurs qui correspondent
# à X[0] et X[0]^2
X_poly[0]
```

Out[14]: array([-0.75275929, 0.56664654])

### 5- Modèle de régression polynomial

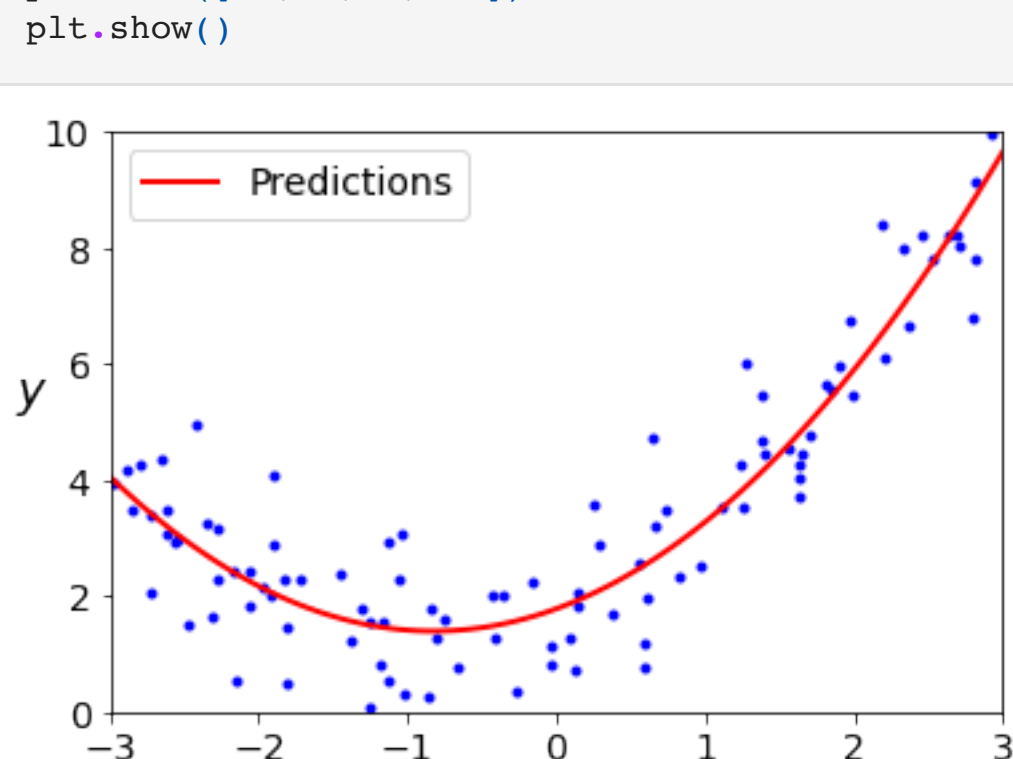
```
In [15]: # On consiste à ajouter les puissances de chacune des
# variables comme nouvelles variables, puis d'entraîner
# un modèle linéaire sur ce nouvel ensemble de données

from sklearn.linear_model import LinearRegression
lin_reg = LinearRegression()
lin_reg.fit(X_poly, y)
lin_reg.intercept_, lin_reg.coef_
```

Out[15]: (array([1.78134581]), array([0.93366893, 0.56456263]))

On obtient les valeurs de  $\theta_0$ ,  $\theta_1$  et  $\theta_2$ . L'équation de régression polynomiale est alors  $y_{pred} = \theta_0 + \theta_1 x + \theta_2 x^2$

```
In [16]: X_new=np.linspace(-3, 3, 100).reshape(100, 1)
X_new_poly = poly_features.transform(X_new)
y_new = lin_reg.predict(X_new_poly)
plt.plot(X, y, "b.")
plt.plot(X_new, y_new, "r-", linewidth=2, label="Predictions")
plt.xlabel("$x_1$", fontsize=18)
plt.ylabel("$y$", rotation=0, fontsize=18)
plt.legend(loc="upper left", fontsize=14)
plt.axis([-3, 3, 0, 10])
plt.show()
```




### 6- Représentation du modèle de régression linéaire et polynomial

```
In [17]: from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import Pipeline

dict={"a","b"}

plt.rcParams.update({'font.size': 16})
fig = plt.figure(figsize=(10, 5))
for style, width, degree in (("b--", 2, 2), ("r+", 2, 1)):
    polybig_features = PolynomialFeatures(degree=degree, include_bias=False)
    std_scaler = StandardScaler()
    lin_reg = LinearRegression()
    polynomial_regression = Pipeline([
        ("poly_features", polybig_features),
        ("std_scaler", std_scaler),
        ("lin_reg", lin_reg),
    ])
    polynomial_regression.fit(X, y)
    y_newbig = polynomial_regression.predict(X_new)
    plt.plot(X_new, y_newbig, style, label=str(degree), linewidth=width)

plt.plot(X, y, "b.", linewidth=3)
plt.legend(loc="upper left")
plt.xlabel("$x_1$", fontsize=18)
plt.ylabel("$y$", rotation=0, fontsize=18)
plt.title("Régression polynomiale")
plt.axis([-3, 3, 0, 10])
plt.show()
```




### 7 & 8- Représentation du modèle de régression linéaire et polynomial d'ordre 2 et d'ordre 300

```
In [18]: from sklearn.pipeline import Pipeline

dict={"a","b"}

plt.rcParams.update({'font.size': 16})
fig = plt.figure(figsize=(10, 5))
for style, width, degree in (("b--", 1, 300), ("r+", 2, 2), ("r+", 2, 1)):
    polybig_features = PolynomialFeatures(degree=degree, include_bias=False)
    std_scaler = StandardScaler()
    lin_reg = LinearRegression()
    polynomial_regression = Pipeline([
        ("poly_features", polybig_features),
        ("std_scaler", std_scaler),
        ("lin_reg", lin_reg),
    ])
    polynomial_regression.fit(X, y)
    y_newbig = polynomial_regression.predict(X_new)
    plt.plot(X_new, y_newbig, style, label=str(degree), linewidth=width)

plt.plot(X, y, "b.", linewidth=3)
plt.legend(loc="upper left")
plt.xlabel("$x_1$", fontsize=18)
plt.ylabel("$y$", rotation=0, fontsize=18)
plt.title("Régression polynomiale")
plt.axis([-3, 3, 0, 10])
plt.show()
```



In [ ]:

In [ ]: